
Сравнительный анализ графовых и гиперграфовых нейронных сетей и их применение в задачах Retrieval-Augmented Generation

A Preprint

Аристеев О. А.
МГУ имени М. В. Ломоносова
Москва, Россия

Прокофьев П. А.
МГУ имени М. В. Ломоносова
Москва, Россия

Abstract

Графовые и гиперграфовые нейронные сети (GNN и HGNN) становятся ключевыми инструментами для анализа данных со сложной структурой. В то время как GNN зарекомендовали себя как фундаментальный метод в обработке графов, HGNN позволяют моделировать более сложные n -арные отношения, выходя за рамки бинарных связей. Настоящее исследование имеет три направления: (1) сравнительный анализ возможностей GNN и HGNN, (2) включение HGNN в рамки Geometric Deep Learning как обобщённой парадигмы обучения на структурированных данных, (3) применение гиперграфов в построении Retrieval-Augmented Generation (RAG) для работы с графами знаний. В работе систематизируются существующие методы, обсуждаются их сильные и слабые стороны, а также выявляются перспективные направления, связанные с интеграцией HGNN и LLM через гиперграфовые представления знаний.

Keywords графовые нейронные сети · гиперграфовые нейронные сети · Geometric Deep Learning · Retrieval-Augmented Generation · LLM

1 Введение

Современные приложения искусственного интеллекта требуют методов, способных обрабатывать сложные структуры данных: от социальных сетей и биологических систем до баз знаний для больших языковых моделей. Классические графовые нейронные сети (GNN) показали высокую эффективность, однако они ограничены моделированием бинарных связей. Гиперграфовые нейронные сети (HGNN) открывают новые возможности, позволяя работать с n -арными отношениями и более богатыми структурными зависимостями.

Одним из подходов является развитие методов HGNN и их сопоставление с GNN по качеству, вычислительной эффективности и устойчивости. Параллельно HGNN могут быть встроены в более широкую теоретическую рамку Geometric Deep Learning, которая рассматривает нейросетевые архитектуры как обобщение принципов симметрий и инвариантностей. Ещё одно направление связано с практическими приложениями: графы знаний, являясь важным источником структурированной информации, могут быть представлены в виде гиперграфов и использоваться в Retrieval-Augmented Generation (RAG). Такой подход позволяет моделировать не только простые пары сущностей, но и сложные факты с несколькими участниками. Сравнительное изучение этих направлений даёт основу для создания более выразительных и интерпретируемых моделей.

В рамках работы предполагается провести сравнительный анализ GNN и HGNN с опорой на современные исследования и бенчмарки. Кроме того, будет рассмотрено место HGNN в общей картине Geometric Deep Learning. Особое внимание планируется уделить применению гиперграфов для представления знаний и их интеграции в RAG, что может расширить возможности LLM за счёт более богатых структурных

представлений. Такой комплексный подход позволит выявить сильные и слабые стороны текущих методов и очертить направления для дальнейших исследований.

2 Литературный обзор

Классические работы по GNN [??] заложили основу для современных моделей, использующих свёртки, агрегацию признаков и механизмы внимания. С другой стороны, HGNN [?] позволили расширить эти идеи на гиперграфовые структуры, что открыло путь к обработке n-арных связей. Современные обзоры [?] и бенчмарки [?] подтверждают рост интереса к HGNN, предлагая классификации методов и стандартизированные наборы данных для их оценки.

Geometric Deep Learning [?] представляет собой общую рамку, объединяющую CNN, GNN, трансформеры и их обобщения через симметрии и инвариантности. HGNN занимают в этой картине особое место, так как они естественно связаны с более высокопорядковыми структурами. Таким образом, HGNN рассматриваются как связующее звено между GNN и более общими методами топологического машинного обучения.

Графы знаний традиционно используются в NLP для представления фактов и связей между сущностями [?]. С появлением RAG [?] возникла новая парадигма — использование внешних структурированных знаний для улучшения генерации. Современные исследования расширяют эту идею: от GraphRAG [?] до HyperGraphRAG [?], где гиперграфовые структуры позволяют интегрировать сложные отношения. Дополнительные работы [??] показывают, что графы знаний могут стать динамическим компонентом памяти LLM-агентов. В этой перспективе HGNN могут стать естественным инструментом для представления и обработки гиперграфов знаний.

Список литературы